Computational Statistics Lecture Notes
2025/2026

João Pires

Instituto Superior Técnico, University of Lisbon, Portugal

December 18th, 2025

1. Monte Carlo Method

O principal objetivo do método do Monte Carlo é resolver problemas matemáticos através de simulação aleatória, como integrais complicadas, que métodos numéricos tradicionais não conseguem resolver. A ideia advém do facto de que uma integral pode ser escrita como um Expected value. Se isto for possível, basta gerar amostras desta distribuição e fazer uma média. Se tivermos uma integral:

$$J = \int_X f(x)\, dx.$$

Onde X é uma variavel aleatória, e conseguirmos decompor $f(x)$ como: $f(x) = g(x)\, h(x)$, onde $h(x)$ é uma densidade de probabilidade, então podemos escrever que:

$$J = \mathbb{E}[g(X)],$$

onde X é uma variável aleatória com densidade $h(x)$. Assim, o problema de integração passa a ser um problema de tarefa de estimação do valor esperado.

1.1. Simple Monte Carlo

Seja $x_1, \ldots, x_n$ uma amostra aleatória independente de $h(x)$. O valor verdadeiro $\mathbb{E}[g(X)]$ é o objetivo, enquanto que o estimador de Monte Carlo ($\hat{J}$) é a aproximação calculada a partir das simulações. O estimador converge para o valor verdadeiro quando n tende para o infinito. O estimador de Monte Carlo para J é:

$$\hat{J} = g_n = \frac{1}{n} \sum_{i=1}^{n} g(x_i). \tag{1}$$

Pela Lei dos Grandes Números, temos que:

$$g_n \to \mathbb{E}[g(X)], \quad \text{quase certamente.}$$

Exemplo: Aproximar $\pi/4$

Para calcular:

$$\int_0^1 \sqrt{1-x^2}\, dx = \frac{\pi}{4},$$

podemos gerar uma amostra uniforme em $(0,1)$ e avaliar $g(x) = \sqrt{1-x^2}$. A média das avaliações aproxima o valor exato. Com 5000 simulações, obtém-se aproximadamente 0.7851. Escolhemos $h(x) = \mathit{Uniform}(0,1)$. Ou seja, o $h(x)$ vai descrever como os valores de X $(x_1, \ldots, x_n)$ vão ser distribuídos. Neste caso, $g(x) = \sqrt{1-x^2}$ e $h(x) = 1$ (Uniforme).

1.2. Aplicação Bayesiana

No cenária bayesiano temos integrais do tipo:

$$\int g(\theta)h(\theta|x)\,d\theta,$$

onde $h(\theta|x)$ é a densidade à posteriori. Se conseguirmos simular alguns valores random da posteriori, $(\theta_{(1)}, \ldots, \theta_{(n)})$, então o expected value posterior é estimado como:

$$\widehat{\mathbb{E}}[g(\theta) \mid x] = \frac{1}{n}\sum_{i=1}^{n} g(\theta_{(i)}). \tag{2}$$

1.3. Estimativa da Variância

A variância do estimador, da equação (1), é dado por:

$$v_n = \frac{1}{n-1}\sum_{i=1}^{n}(g(x_i) - \overline{g_n})^2.$$

Para n grande, temos a aproximação normal:

$$\frac{\overline{g_n} - \mathbb{E}_h[g(X)]}{\sqrt{v_n}} \overset{a}{\sim} N(0,1).$$

Num cenário bayesiano, a precisão do estimador de Monte Carlo (2) pode ser medido pelo Monte carlo standard error (estimado), dado por:

$$\frac{1}{\sqrt{n(n-1)}}\left\{\sum_{i=1}^{n}\left[g(\theta^{(i)}) - \frac{1}{n}\sum_{i=1}^{n} g(\theta^{(i)})\right]^2\right\}^{1/2},$$

quando $E\{[g(\theta)]^2 \mid x\}$ é finito.

1.4. Quantidades Posteriores Estimáveis com Monte Carlo

Após gerar amostras da posterior $h(\theta|x)$, é possível estimar:

- probabilidades posteriores,
- densidades marginais,
- intervalos de credibilidade,
- distribuições preditivas.

1.5. Probabilidades Posteriores

Se pretenderes calcular a probabilidade posterior de um evento A, então:

$$P(\theta \in A) = \mathbb{E}[I_A(\theta)]\,,$$

onde $I_A(\theta)$ é a função indicadora do evento A. O estimador de Monte Carlo é dado por:

$$\hat{P} = \frac{\#\{\theta^{(i)} \in A\}}{n}.$$

Ou seja, simplesmente contas quantas das amostras simuladas $\theta^{(i)}$ satisfazem o evento A, e divides pelo número total de simulações.

1.6. Densidade Marginal

A densidade marginal é a densidade de probabilidade de uma variável quando ignoramos as restantes (integramos sobre estas restantes). Quando $\theta = (\theta_1, \theta_2)$, a densidade marginal de θ_1 pode ser escrita como:

$$h(\theta_1 \mid x) = \int h(\theta_1 \mid \theta_2, x)\, h(\theta_2 \mid x)\, d\theta_2.$$

1.7. Técnicas de redução de variância

O método de Monte Carlo tem um problema no quesito de redução do seu erro padrão. Se quisermos reduzir o erro padrão em 100x, precisamos de 10 000x mais amostras. O que é computacionalmente muito caro, e daí surgem técnicas de redução da variância.

1.7.1 Antithetic Variables

Uma ideia para reduzir a variança é gerar pares de valores negativamente correlacionados. Por exemplo, se tivermos uma variável a seguir uma distribuição Uniforme (1,0), então criamos um outro conjunto de valores 1-Uniforme (1,0), têm ambas a mesma distribuição, mas estão negativamente correlacionadas. Se g for uma função monótoma, então os valores $g(U)$ e $g(U-1)$ também são negativamente correlacionados. Ao fazer a média destas duas variáveis, negativamente correlacionadas, reduzimos a variância.

$$\hat{J} = \frac{1}{n} \sum_{j=1}^{n/2} \left[g(U_j) + g(1 - U_j) \right].$$

1.7.2 Monte Carlo com Importance Sampling

Muitas vezes temos uma distribuição pouco eficiente, isto é, os valores que gera pouca importância têm para o cálculo da integral. Por exemplo, temos:

$$f(x) = \int e^{-x^2} dx,$$

com Monte Carlo simples usando $X \sim \text{Uniform}(-10, 10)$. O termo e^{-x^2} só tem valores relevantes perto de 0. Mas a distribuição gera valores que estão muito longe de 0, o que vai ter uma contribuição nula para o cálculo da integral, e aumenta a variância. Portanto, escolhemos uma distribuição que gera frequentemente valores nas regiões onde o integrando é relevante. Para estimar:

$$J = \int g(x)\, dx,$$

escolhe-se uma densidade $p(x)$ definida onde $g(x) > 0$ e escreve-se:

$$J = \mathbb{E}\left[\frac{g(X)}{p(X)}\right], \quad X \sim p.$$

O estimador é então:

$$\hat{J} = \frac{1}{n} \sum_{i=1}^{n} \frac{g(X_i)}{p(X_i)}.$$

Escolher $p(x)$ de forma adequada pode reduzir drasticamente a variância — idealmente, $p(x)$ deve ser aproximadamente proporcional a $|g(x)|$.

1.8. Basic rejection algorithm

O Método de Rejeição é uma técnica fundamental utilizada quando se pretende gerar amostras de uma distribuição de probabilidade complexa, designada por **densidade alvo** $\pi(x)$, da qual é difícil amostrar diretamente. A intuição matemática reside na utilização de uma distribuição auxiliar mais simples, designada por **densidade instrumental** ou de proposta $p_u(x)$, que sabemos simular facilmente. Para que o método funcione, define-se uma constante $M > 1$ tal que a função envelope $Mp_u(x)$ cubra completamente a densidade alvo em todo o seu suporte, isto é:

$$\pi(x) \leq Mp_u(x), \quad \forall x.$$

O algoritmo baseia-se num processo de aceitação ou rejeição estocástica:

1. Gera-se um candidato y a partir da distribuição instrumental p_u.
2. Gera-se um número aleatório u de uma distribuição Uniforme(0,1).
3. A decisão de aceitar o candidato y como uma amostra válida de $\pi(x)$ depende da razão entre a densidade alvo e a função envelope avaliada em y.
4. Se $u \leq \frac{\pi(y)}{Mp_u(y)}$, aceita-se y.
5. Caso contrário, rejeita-se e reinicia-se o processo.

Geometricamente, isto equivale a lançar pontos aleatórios uniformemente na área abaixo da curva envelope e aceitar apenas aqueles que caem abaixo da curva da densidade alvo. A eficiência deste método está diretamente ligada à escolha da constante M e da densidade instrumental. O ideal é que a curva envelope $Mp_u(x)$ esteja o mais próxima possível da densidade alvo $\pi(x)$. Se M for muito grande, a área de rejeição será vasta, resultando em muitos candidatos descartados. Matematicamente, a probabilidade de aceitação de um candidato é $1/M$; portanto, quanto menor for o M (respeitando a condição de envelope), mais eficiente é o algoritmo. Uma aplicação clássica ocorre na inferência Bayesiana para amostrar de uma distribuição a posteriori $h(\theta|x)$ conhecendo apenas o seu núcleo.Se a distribuição a priori $h(\theta)$ for própria, pode-se usá-la como envelope, definindo M como o valor máximo da função de verossimilhança $f(x|\theta)$.

1.9. Adaptive Rejection Sampling - ARS

O Método de Rejeição Adaptativa (ARS) surge para resolver a dificuldade de encontrar manualmente uma função envelope eficiente. Este método é aplicável especificamente para densidades cuja função logarítmica é côncava (**log-côncavas**). A propriedade de log-concavidade garante que o gráfico de $L(x) = \ln \pi(x)$ tem a forma de uma "colina" suave, permitindo a construção automática de envelopes lineares por seções. A construção dos envelopes utiliza tangentes e cordas no gráfico do logaritmo da densidade:

- **Envelope superior $u_k(x)$:** Formado por linhas tangentes à curva $L(x)$ em pontos pré-selecionados, garantindo que a densidade alvo nunca ultrapasse este limite.
- **Envelope inferior $l_k(x)$:** Formado por cordas (linhas secantes) que ligam esses pontos, ficando sempre abaixo da curva .

Ao exponenciarmos estas linhas, obtemos funções que "envelopam" a densidade alvo $\pi(x)$. O algoritmo ARS introduz um passo de eficiência chamado de **"squeezing"** (espremimento). Para cada candidato gerado a partir do envelope superior:

1. Realiza-se um teste rápido usando o envelope inferior.
2. Se o candidato for aceite pelo envelope inferior ($u \leq \exp\{l_k(x) - u_k(x)\}$), é automaticamente aceite como amostra válida, evitando o cálculo custoso de $\pi(x)$.
3. Apenas se falhar no teste inferior é que se avalia a função real para o teste de rejeição padrão.

Sempre que um candidato passa pelo teste de rejeição padrão (exigindo o cálculo de $L(x)$), esse ponto é adicionado ao conjunto de suporte T_k. Isso refina os envelopes, tornando o método progressivamente mais eficiente à medida que a amostragem ocorre.

1.10. Lecture Notes

Importance sampling: Saber que $g(x)$ tem o expected value $E(g(X))$ e que $\hat{I} = \frac{1}{n}\sum_{i=1}^{n} g(x_i)$. Se tivermos um:

$$I = \int_0^1 g(x)\,dx,$$

podemos assumir que $h(x) = 1$. Se tivermos um:

$$I = \int_A^B g(x)\,dx,$$

podemos multiplicar (dentro da integral) por $1/(b-a)$ e multiplicar $(b-a)$ fora da integral:

$$I = (b-a)\int_A^B g(x)\,\frac{1}{b-a}\,dx,$$

e temos que:

$$h(x) = \frac{1}{b-a}, \quad a < x < b; \qquad 0 \text{ otherwise.}$$

Neste caso,

$$\hat{I} = (b-a)\cdot\frac{1}{n}\sum_{i=1}^{n} g(x_i),$$

com $x_1, \ldots, x_n \sim U(a,b)$. Às vezes temos de criar uma distribuição melhor que $h(x)$; podemos criar uma distribuição $p(x)$ (semelhante a $f(x)$) e dividir por $p(x)$ também. Ficamos com

$$I = \int g(x)\frac{h(x)}{p(x)}\,p(x)\,dx.$$

A melhor, num cenário geral, será escolher $p(x)$ sendo a distribuição Gaussiana. Usamos sempre $E(X)$ porque $E(x)$ é data, é sempre em função da variável aleatória. Quando temos $f(x \mid \theta)$ é um classical approach. $\mathrm{Var}(X) = \sigma^2$, $\mathrm{Var}(\bar{X}) = \sigma^2/n$ (para variáveis independentes). Standard error: $\sqrt{\mathrm{Var}(X \mid \theta)/n}$ e standard deviation $(X \mid \theta)$: $\sqrt{\mathrm{Var}(X \mid \theta)}$. Num cenário Bayesiano, temos que

$$h(\theta \mid x) = c\,f(x \mid \theta)\,h(\theta),$$

onde c é a integral. Ficamos com

$$I = E(g(\theta \mid X)) = \int g(\theta)\,h(\theta \mid x)\,\frac{p(\theta)}{p(\theta)}\,d\theta.$$

Às vezes podemos usar a proposal como a prior $h(\theta)$. Como $f(x \mid \theta)$ é o likelihood, podemos escrever $f(x \mid \theta) = L(\theta \mid x)$. Se desdobrarmos:

$$I = \int g(\theta)\, h(\theta \mid x)\, \frac{p(\theta)}{p(\theta)}\, d\theta,$$

temos que:

$$I = \frac{\int g(\theta)\, w(\theta)\, p(\theta)\, d\theta}{\int w(\theta)\, p(\theta)\, d\theta},$$

onde:

$$w(\theta) = \frac{f(x \mid \theta)\, h(\theta)}{p(\theta)}.$$

Escrevemos o estimador como:

$$\hat{I} = \frac{1}{\sum_{i=1}^{n} w_i} \sum_{i=1}^{n} w_i\, g(\theta_i),$$

o qual converge para:

$$\int g(\theta)\, h(\theta \mid x)\, d\theta.$$

Stor deu enfâse ao exemplo 3.5 dos apontamentos. Stor deu enfâse ao basic rejection algorithm.

2. Markov Chain Monte Carlo Methods

Os métodos de MCMC (Markov Chain Monte Carlo), são utilizados para gerar amostras para um distribuição de probabilidade à posteriori, $h(\theta|x)$. Basicamente, criamos uma cadeia de markov, processo estocástico em que o estado futuro depende apenas do estado atual, que, aquando a sua estabilização, a distribuição estabilizada é a nossa à posteriori, $h(\theta|x)$. Uma vez que a cadeia atinge a estabilização, os valores gerados subsequente podem ser tratados como amostras da distribuição de interesse. Podendo, depois, fazer inferências.

Um processo estocástico não passa da coleção das observações feitas de um evento aleatório. É uma sequência de variáveis aleatórias, onde cada uma está associada a um tempo específico, t. Se o tempo for contado em passos discretos, passo 0, passo 1, passo 2, etc., temos um tempo discreto, onde está denotado por $\{U_n, n \geq 0\}$. O conjunto de todos os valores possíveis que o processo pode obter, chama-se espaço de estados. A cadeia de markov é um tipo de processo estocástico com uma propriedade especial, não tem memoria do passado. O estado futuro depende apenas do estado atual. Matematicamente, pela probabilidade condicional, a probabilidade do processo ir para um estado A no tempo $n+1$ depende apenas do valor no tempo n, e não dos valores anteriores. Caso isto seja satisfeito, temos a propriedade de Markov.

$$P(U_{n+1} \in A | U_0 = u_0, \ldots, U_n = u) = P(U_{n+1} \in A | U_n = u) \equiv P_n(u, A).$$

A distribuição estacionária representa o equilíbrio da cadeia a longo prazo. Quando uma distribuição $\pi(u)$ é estacionária, se o processo começar distribuído segundo π ela segue a distribuição para todo o sempre (condição de estabilidade). Matematicamente, a probabilidade de estar num estado $\pi(v)$ é igual à soma das probabilidades de estar em qualquer estado $\pi(u)$ multiplicado pela probabilidade de transitar de u para v, $p(u, v)$:

$$\pi(v) = \sum_{u} \pi(u) p(u, v).$$

2.1. Algoritmo Metropolis-Hastings (M-H)

O algoritmo Metropolis-Hastings (M-H) é dos métodos mais utilizados em MCMC. Ele permite gerar amostras da distribuição alvo, $\pi(u)$, a partir de uma distribuição proposta $q(v|u)$. A distribuição proposta não tem de ser igual à distribuição alvo, mas tem de ser fácil de estimar. A distribuição proposta, vai gerar um candidato v dado o estado atual u, onde a aceitação desse candidato tem uma probabilidade α. O processo é iterativo e indexado pelo tempo t. Dado um estado atual $u^{(t)}$:

1. Gera-se um candidato $v^{(t)}$ a partir de $q(\cdot|u^{(t)})$.
2. Gera-se um número aleatório z de uma distribuição Uniforme(0,1).
3. Se $z \leq \alpha(u^{(t)}, v^{(t)})$, a transição é aceite: $u^{(t+1)} = v^{(t)}$.
4. Caso contrário, a transição é rejeitada e a cadeia permanece no mesmo local: $u^{(t+1)} = u^{(t)}$.

A distribuição proposta é denotada por $q(v|u)$ (ou equivalentemente $q(u, v)$), e serve como o mecanismo gerador de novos estados candidatos. O passo crucial é o cálculo da razão Metropolis-Hastings (α). A probabilidade de se aceitar v é dada por:

$$\alpha(u, v) = \min\left\{\frac{\pi(v)q(u|v)}{\pi(u)q(v|u)}, 1\right\}.$$

Se o candidato for aceite, a cadeia move-se para v, caso contrário, permanece em u e o valor u é repetido. As letras maiúsculas ($U^{(t)}$, $V^{(t)}$) representam as **Variáveis Aleatórias**. As letras minúsculas ($u^{(t)}$, $v^{(t)}$) representam os **valores realizados** (números concretos) nessas iterações. Algumas variações importantes deste algoritmo são o Independence M-H algorithm, e o Random walk M-H algorithm. Para o Independence M-H algorithm, aqui temos que $q(v|u) = q(v)$, não há dependência do estado atual $u^{(t)}$. Ao contrário do Random Walk, o novo candidato é sorteado de uma distribuição fixa, independentemente de onde a cadeia se encontra no momento. E temos que α, é:

$$\alpha(u^{(t)}, v^{(t)}) = \min\left\{\frac{\pi(v^{(t)})q(u^{(t)})}{\pi(u^{(t)})q(v^{(t)})}, 1\right\}, \quad t \geq 0.$$

Um caso comum é usar a distribuição *a priori* como proposta ($q(\theta) = h(\theta)$). Nesse caso, a razão de aceitação torna-se apenas o rácio das verosimilhanças: $\alpha = \min\{\frac{L(v|x)}{L(u|x)}, 1\}$. No Random Walk M-H, temos que $q(v|u) = q^*(v-u)$ (a proposta depende explicitamente de onde estamos). O candidato é uma perturbação aleatória do estado atual ($v = u + \epsilon$), é útil quando não temos muita informação da distribuição alvo.

2.2. Gibbs Sampling

O Gibbs sampling é utilizado para simular distribuições multivariadas. Normalmente casos em que temos a nossa distribuição a posteriori, com um vetor de parâmetros θ, onde $\theta = (\theta_1, \ldots, \theta_k)^T$. Pode ser determinado por k distribuições condicionais completas a posteriori (*full conditional posterior distributions*):

$$h(\theta_j|\theta_{-j}, x), \quad j = 1, \ldots, k.$$

No fundo, o problema multivariado é decomposto em problemas uni-variados mais simples. O funcionamento deste algoritmo é um esquema iterativo e sequencial. Inicialmente,

atribuímos valores arbitrários para todos os parâmetros, $\theta^{(0)} = (\theta_1^{(0)}, \ldots, \theta_k^{(0)})^T$. Em cada iteração, atualizamos um parâmetro de cada vez, $\theta_1^{(l)} \sim h(\theta_1 \mid \theta_2^{(l-1)}, \ldots, \theta_k^{(l-1)}, x)$. O ponto crucial é que, ao atualizar o parâmetro θ_j, utilizamos sempre os valores mais recentes dos outros parâmetros já atualizados na mesma iteração. Este processo cria uma cadeia de Markov onde a probabilidade de transição é o produto dessas condicionais:

$$p(\theta^{(s)}, \theta^{(s+1)}) = \prod_{j=1}^{k} h(\theta_j^{(s+1)} \mid \theta_{l>j}^{(s)}, \theta_{l<j}^{(s+1)}, x).$$

Quando $s \to \infty$, o vetor de parâmetros na iteração s, $\theta^{(s)} = (\theta_1^{(s)}, \ldots, \theta_k^{(s)})^T$, tende para uma distribuição de um vetor aleatório com função densidade de probabilidade (p.d.f) $h(\theta|x)$. Após o período de aquecimento (*burn-in*), as amostras geradas convergem para a distribuição conjunta alvo. Uma propriedade muito útil do Gibbs Sampling é que, para obter a distribuição marginal de qualquer parâmetro θ_j, basta olhar para a coleção de valores amostrados para esse componente específico, ignorando os outros:

$$h(\theta_j \mid x) \approx \frac{1}{m} \sum_{l=1}^{m} h(\theta_j \mid \theta_{-j}^{(l)}, x).$$

Além disso, o método facilita a inferência preditiva: a densidade preditiva para novos dados y pode ser estimada simplesmente pela média das verosimilhanças calculadas com os parâmetros amostrados:

$$\tilde{p}(y \mid x) = \frac{1}{m} \sum_{l=1}^{m} f(y \mid \theta^{(l)}, x).$$

2.3. Convergence Diagnostic Techniques

Os métodos MCMC garantem apenas convergência apenas quando o número de iterações tende para infinito. Portanto, utilizamos ferramentas para diagnosticar se a cadeia já estabilizou na distribuição alvo. Podemos dividir estes diagnósticos em duas partes principais, a monitorização da distribuição estacionária e a monitorização das médias empíricas.

No que toca à monitorização da distribuição, o objetivo é verificar se a cadeia de Markov já se esqueceu do seu ponto de partida e está a visitar o espaço de estados de acordo com a estacionariedade. Aqui podemos utilizar a inspeção visual (computar gráficos ao longo das iterações e ver se há um ruído estável em torno de um valor médio), podemos utilizar a sobreposição de densidades (onde há comparação das estimativas da densidade marginal calculadas em diferentes números de iterações, se há estabilização aumentar o numero de iterações não muda nada), e por fim podemos utilizar testes não paramétricos, como o teste de Kolmogorov-Smirnov para comparar duas sub-amostras da cadeia.

Agora no que toca à monitorização das médias empíricas, o principal objetivo é ver se o integral de interesse $E[g(\theta)|x])$ já convergiu para o valor real. Podemos utilizar o Mean Evolution Plot, onde computa-se o gráfico da média acumulada à medida que as iterações avançam, ou podemos utilizar as Somas Acumuladas (CUSUM), onde há o cálculo da soma cumulativa dos desvios de cada valor em relação à média global (D_l).

2.3.1 Gelman and Rubin Method

Este método distingue-se por utilizar múltiplas cadeias ($m \geq 2$) iniciadas em pontos de partida dispersos, em vez de uma única. A intuição matemática baseia-se na Análise de Variância (ANOVA): compara-se a variância dentro de cada cadeia (W) com a variância entre as diferentes cadeias (B). Se todas as cadeias tiverem convergido para a mesma distribuição alvo, a variância entre elas deve diminuir e tornar-se consistente com a variância interna. O diagnóstico resume-se ao cálculo do fator de redução de escala $\hat{R} = \sqrt{V/W}$. À medida que o número de iterações (n) tende para o infinito, este rácio deve aproximar-se de 1; valores de $\hat{R} \approx 1$ indicam que as cadeias convergiram para a distribuição de equilíbrio.

2.3.2 Geweke Method

O método de Geweke analisa a convergência de uma única cadeia tratando-a como uma série temporal. A lógica é verificar a estabilidade comparando duas "janelas" da simulação: uma parte inicial (geralmente os primeiros 10% ou 20% após o burn-in) e uma parte final (os últimos 50%). Se a cadeia é estacionária, as médias destas duas partes (g_a e g_b) devem ser estatisticamente iguais. O método calcula uma estatística Z que pondera a diferença das médias pelas suas variâncias assintóticas; se o valor resultante for compatível com uma distribuição Normal padrão $N(0, 1)$, assume-se que há convergência.

2.3.3 Raftery and Lewis Method

Diferente dos anteriores, este método foca-se no planeamento da simulação, especificamente quando o objetivo é estimar quantis com uma tolerância e probabilidade pré-definidas. O método calcula a priori quantas iterações (N) e qual o tamanho do período de aquecimento (M) são necessários para garantir essa precisão. Uma métrica crucial produzida é o "fator de dependência" (I). Se $I > 5$, isso serve como um alerta de que a cadeia tem alta auto-correlação ou má mistura ("poorly mixed"), indicando que a convergência será lenta e que os valores iniciais podem estar a influenciar demasiado o resultado.

2.3.4 Heidelberg and Welch Method

Este método aplica um teste de hipóteses formal (baseado no teste de Cramer-von Mises) para validar a estacionariedade de uma cadeia. O procedimento é iterativo: testa-se a hipótese nula de que a cadeia é estacionária. Se rejeitada, o algoritmo descarta os primeiros 10% da cadeia e repete o teste. Este ciclo continua até a cadeia passar no teste ou até 50% dos dados serem descartados (o que indicaria falha na convergência). Se a estacionariedade for aceite, o método aplica ainda um segundo critério de precisão para verificar se a estimativa da média tem um erro padrão suficientemente pequeno em relação à própria média .